Analisis y Curacion clase 4: Práctico 2

30 de Mayo, 2019, Cohorte Alpha

Análisis exploratorio y curación de datos

- Gonzalez Nehuen
- Arja Adel
- Madoery Pablo

Practico 2: Entregar un Rmd donde se:

- Elija un dataset clasificado de su preferencia y area (domain expertise), aplique un metodo de clustering y/o mixtura de Gaussianas en el mismo.
- Investigue los resultados en el meta parametro K numero de cumulos e investigue posibles procesos de seleccion del mismo.
- Elabore un resumen, y selecione un mejor valor segun el/los criterios aplicados, discuta el significado de los cumulos encontrados.
- Comente la influencia de la normalizacion de los datos en los resultados del clustering.

Solución

Utilizamos el método “k-Nearest Neighbour”, con el cual realizamos la clasificación de un data set de distintos tipos de vidrios.

El data set fue descargado de https://archive.ics.uci.edu/ml/datasets/glass+identification.

```
### Cargamos el data set en un data frame
glass_df = read.csv("glass.csv", header = FALSE)

### Le ponemos los nombres a las columnas de acuerdo a la
colnames(glass_df) <-
  c("id", "RI", "Na", "Mg", "Al", "Si", "K", "Ca", "Ba", "
```

```r
### transformamos la columna de clasificación a string
glass_df$Type <- as.character(glass_df$Type)
### hacemos un shuffle de las filas del data frame para no
### en errores de inferencias triviales
glass_df <- glass_df[sample(nrow(glass_df)),]

### normalizamos los valores numéricos
normalize <- function(x) {
return ((x-min(x))/(max(x)-min(x)))
}
glass_df_n <- as.data.frame(lapply(glass_df[2:10], normaliz
```

```
### definimos un conjunto de datos para entrenamiento y ot
glass_df_n_train = glass_df_n[1:100,]
glass_df_n_test = glass_df_n[101:214,]
train_types = glass_df[1:100, "Type"]
test_types = glass_df[101:214, "Type"]
```

```r
### Realizamos "N_reps" repeticiones y calculamos la eficie
### (que guardamos finalmente en un vector v)
library(class)
v = rep(0, 15)
N_reps = 10
for (j in 1:N_reps){
  for (k in 1:15){
    data_test_pred <- knn(train=glass_df_n_train, test=glas
    v[k] <- v[k] + sum(data_test_pred == test_types) / leng
  }
}
v <- v/N_reps
plot(1:15, v, ylim=c(0,1))
```

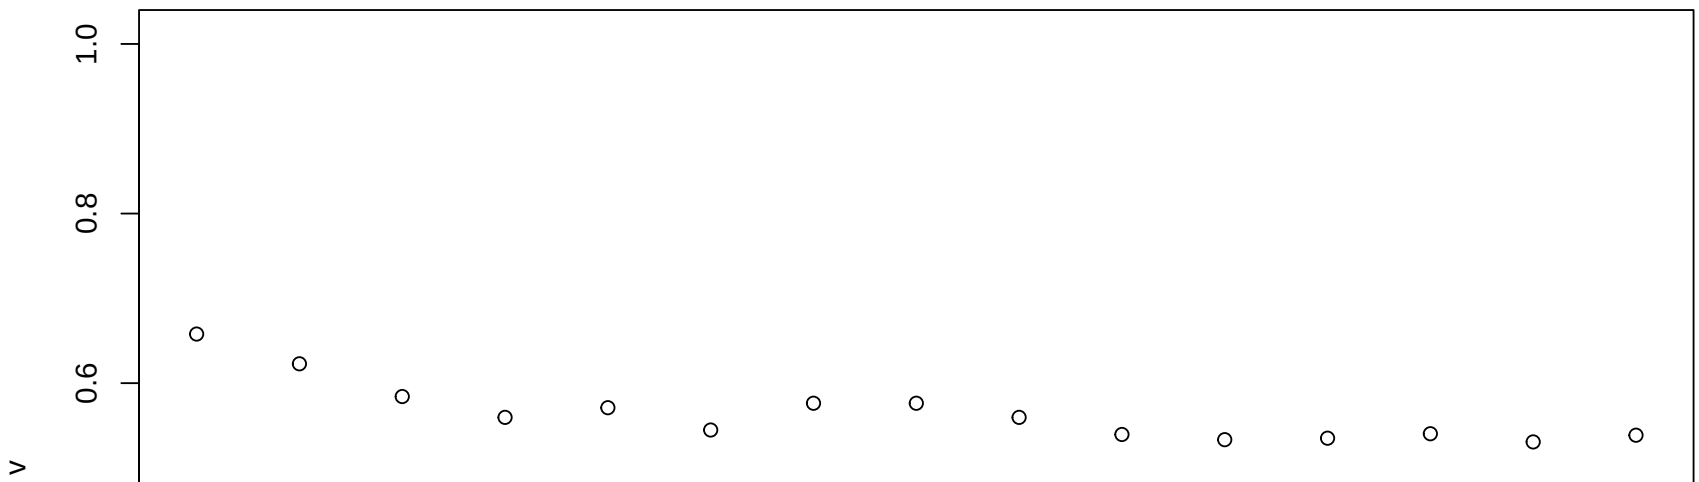

```r
### Calculamos la Crosstable para ver la eficiencia en la
library(gmodels)
CrossTable(x=test_types, y=data_test_pred, prop.chisq = FAI
```

```
##
##
##    Cell Contents
## |-------------------------|
## |                       N |
## |           N / Row Total |
## |           N / Col Total |
## |         N / Table Total |
## |-------------------------|
##
##
## Total Observations in Table:  114
##
##
##                | data_test_pred
##   test_types |         1 |         2 |         5 |
```